

解 説

推薦システムのアルゴリズム (3)

Algorithms for Recommender Systems (3)

神 嶋 敏 弘

Toshihiro Kamishima

産業技術総合研究所

National Institute of Advanced Industrial Science and Technology (AIST).

mail@kamishima.net, http://www.kamishima.net/

Keywords: recommender system, collaborative filtering, content-based filtering, serendipity, privacy, shilling, GroupLens.

この連載では全 3 回で、利用者が好むであろうものを予測して提示する推薦システムのアルゴリズムについて解説する。最終回である今回は、11 章～16 章を掲載する。なお、本稿で用いる記号の定義を表 3 にまとめた。

11. 嗜好の予測：内容ベースフィルタリング

6 章で述べたように、内容ベースフィルタリングを、やや広義に捉え、アイテムや利用者自身の特徴に基づく推薦手法とした。この内容ベースフィルタリングについて、次の三つの観点から述べる。

- 特徴の種類：アイテムの特徴、デモグラフィックな特徴、コンテキストの特徴
- 入力形式：嗜好データと検索質問
- 推薦規則の獲得：学習による獲得と人手による定義

これらのうち、特徴の種類については 5.5 節で述べたので、残り二つについて述べる。

11.1 入 力 の 形 式

入力形式には嗜好データと検索質問とがある。嗜好データは、利用者の嗜好の度合いを示したデータで、間接指定型内容ベースフィルタリング [Condcliff 99, 村上 05, 小野 06] で用いられる。個々のデータの推薦への寄

与は小さいので、継続的にデータを集積する必要がある。そのため、永続的個人化 (2.1 節) のために主に利用する。

もう一方の検索質問とは、6 章の冒頭で述べたような、アイテムの特徴に対する制約であり、直接指定型の内容ベース [Ricci 07, Smyth 03, Smyth 04, Thompson 04] で利用される。特に、候補アイテムがテキストで、検索質問に索引語が利用される場合には情報検索 [徳永 99] そのものとなる。こうしたシステムは対話的に動作し、徐々に制約を強くして候補を絞り込むものが多い (14.1 節)。このような明示的な検索質問のほかに、暗黙的なものもある。例えば、論文の推薦システムである CiteSeer [Lawrence 99] では、現在閲覧している論文を検索質問とみなし、その論文と本文テキストや引用文献リストが類似している文献を推薦する。検索質問は、継続的に蓄積しなくても利用者の嗜好に関する情報を得られるので、一時的個人化 (2.1 節) のために主に利用する。

11.2 推薦規則の獲得

推薦するアイテムを決定する規則は、機械学習によって獲得する場合と、人手によって定義する場合がある。学習による獲得は、永続的な推薦を嗜好データを用いて行う場合に採用する場合が多い。機械学習問題としては、クラス分類問題 (識別問題) [麻生 06, Bishop 06, Bishop 08, 元田 06, 渡辺 05] に該当する問題である。嗜好データの好き・嫌いをクラスとみなす。一方、特徴ベクトルは、嗜好データを獲得したときのアイテム、デモグラフィック、コンテキストの特徴で構成する。これらのクラスと特徴ベクトルの対を訓練事例とし、機械学習アルゴリズムを適用すれば、アイテム、デモグラフィック、コンテキストの特徴から、利用者のアイテムへの嗜好を予測できるようになる。嗜好データを順序付きカテゴリーとみなす場合は、順序回帰問題 [Agresti 03] として捉えることもできる。検索質問入力を採用した場合にも機械学習によって推薦規則を洗練する方法もある [Thompson 04]。この方法では、検索質問で頻繁に利用される特徴や属性値について、類似度判定の際の重みを増やして、将来の検索で重視するようにしている。

表 3 本稿の主な記号表記一覧

a	: 活動利用者を示す添字
n	: 総利用者数
m	: 総アイテム数
\mathcal{U}	: 利用者の定義域 $\{1, \dots, n\}$
\mathcal{U}_j	: アイテム j を評価した利用者の集合
\mathcal{I}	: アイテムの定義域 $\{1, \dots, m\}$
\mathcal{I}_i	: 利用者 i が評価したアイテムの集合
\mathcal{R}	: 評価値の定義域 (そのほかに欠損値もある)
s_{ij}	: 利用者 i のアイテム j への評価値
S	: s_{ij} を要素とする行列
\bar{s}_i	: \mathcal{I} 中のアイテムへの評価値の平均
\bar{s}_j	: \mathcal{U} 中の利用者アイテム j への評価値の平均
x	: 利用者を示す確率変数
y	: アイテムを示す確率変数
r	: 評価値を示す (確率) 変数
$(Y^{(t)})$: アイテムの時系列

もう一方の人手による定義とは、利用者が与えた効用関数、IF-THEN 型ルール、または類似度関数などに基づいて、推薦するアイテムを決める方法である。[Burke 02] では、効用ベース (utility-based) と知識ベース (knowledge-based) とに分類されている方法である。入力が検索質問の場合には、類似度関数を用いて検索質問の近傍を推薦する手法が多用されている。こうした規則は、人間がヒューリスティックに作成するため、複雑で予測精度の高いものをつくるのは難しい。だが、純粋に手作業で定義するのではなく、学習により獲得した評価値をヒューリスティックな規則で修正することは比較的容易で、有用である。例えば、特売品の予測評価値を増加させたり、在庫がない商品の予測評価値を下げたりといったように、システム管理者側の意図を反映させる場合などである。

12. 嗜好の予測：まとめ

ここでは、協調フィルタリングと内容ベースの二つの予測手法を組み合わせたハイブリッド法について述べた後、アルゴリズムの選択の指針について述べる。

12.1 ハイブリッド法

6 章では、協調と内容ベースの 2 種類の推薦手法を紹介し、それぞれの長所と短所を述べた。簡単にまとめると、協調フィルタリングはほかの利用者の意見に基づいて推薦する方法で、アイテム特徴のデータベースが不要であることや、セレンディピティの高い推薦ができるなどの利点がある。一方、内容ベースフィルタリングは、アイテムや利用者の特徴に基づいて推薦する方法で、新規のアイテムでも推薦できるなどの利点がある。ここで、ほかの利用者の意見とアイテムの特徴は相反する情報ではなく、同時に獲得できる。そこで、互いの長所を生かすように、二つの手法を組み合わせたハイブリッド法について述べる。このハイブリッド法の分類を、[Burke 02] の分類に最近の研究を含めて再編した分類として示す。なお、結合が疎なものから、より密接なものへ順に並べた。研究の動向も、より密接な結合方法へ展開しているといえるだろう。

§1 混合 (mixed)

これは、協調と内容ベースの両方の手法による推薦結果を同時に混合させて提示する方法である。どちらを採用するかは利用者に任されている。

論文の適切な査読者を探すシステム [Basu 01] は、内容ベースと協調フィルタリングの二通りの推薦機能を備える。どちらを使うかは利用者が決める。

§2 切換え (switching)

何らかの規準に基づいて、内容ベースと協調の推薦手法を切り換える方法である。嗜好データが少ないときは、比較的、疎なデータに強い協調フィルタリングを利用し、

十分なデータが蓄積されれば内容ベースに切り換えるという規準がある。また、新規アイテムに対しては、協調フィルタリングは利用できないので内容ベースで推薦を行うが、そのアイテムへの嗜好データが蓄積されれば協調フィルタリングを使うという規準も考えられる。

§3 メタ推薦 (meta-recommendation)

メタ推薦とは個別に得られた各推薦手法の推薦結果を統合する方法である。情報検索で、複数の検索結果を統合するメタ検索エンジン [Dwork 01] と同様の手法である。この方法には、各手法を改造する必要がないため実装が容易である利点がある。

P-Tango[Claypool 99] では、内容ベースと協調のスコアの重み付き線形和を、全体のスコアとする。内容ベースと協調のスコアの重みは初期的には同じである。その後、推薦結果を利用者が受け入れたかどうかのフィードバックに基づいて、それぞれの手法の重みを変化させている。

Pazzani の方法 [Pazzani 99] では、各手法による推薦リストの 1～5 位に、それぞれ 5～1 点を与え、各アイテムの総点数に基づいて最終的な推薦順位を決定する Borda count 法 [de Borda 95] によって統合する。

TiVo[Ali 04] では、基本的には予測評価値で整列してアイテムを提示するが、評価値が同じなら協調フィルタリングのほうを内容ベースより上位に表示する。

§4 縦続 (cascade)

この手法では、最初の段階で候補集合を生成し、次段階でその候補集合から詳細な推薦をする。候補を限定することで、推薦を高速化し、また、条件から大きくかけ離れたアイテムを推薦することを回避できる。

EntreeC[Burke 02] はレストランの推薦システムである。最初の段階では、価格帯や和洋中など、希望するレストランの特徴を示した検索質問を用いて、内容ベースの手法で候補となるレストランを選び出す。その後、協調フィルタリングによって、候補の順位付けをする。

Google News[Das 07] では、利用者が指定した言語やジャンルや、記事の新しさなどで候補記事を絞り込んだのち、協調フィルタリングでより個人化した推薦を行う。逆に、推薦リストを提示した後に、具体的な条件でフィルタリングする手法 [Swearingen 01] も論じられている。こうした簡単な条件による推薦候補の絞り込みは、実装が容易な割に利用者の満足を高めるとされているので [Swearingen 01]、ぜひ導入しておくべきであろう。

§5 特徴拡張 (feature augmentation)

特徴拡張とは、一方の手法が出力する評価値や分類結果を、もう一方の手法の入力とするアプローチである。上記の縦続接続では、二つの推薦器の出力を優先度をつけるが、特徴拡張では、一方の出力がもう一方の入力となる点異なる。

Libra[Mooney 99] は書籍の推薦システムで、Amazon.com から取得した書籍情報の特徴に基づいて内容ベースの推薦を実行する。このとき、Amazon.com 内の協調フィル

タリングによって抽出された関連書籍を、書籍の特徴に含めることで協調フィルタリングの要素を加えている。協調フィルタリングにより求めた類似アイテムをアイテムの特徴に反映させる手法は、SmartPad[Lawrence 01]にも見られる。

Good らの方法 [Good 99] は、人間の標本利用者のほかに、アイテムの特徴に基づいて嗜好を判断する仮想エージェント利用者も参加させて協調フィルタリングをする。仮想エージェント利用者には、特定のジャンルの映画に高い評価値を与えるものなどがある。こうして、内容ベースの推薦の要素を加える。

§ 6 抽象情報 (abstraction)

これは、ほかの利用者の嗜好データや各種の内容データを、ベクトルや確率分布の形式の、メタレベルの抽象的な情報に変換し、別の推薦器に入力する方法である。特徴拡張とは、推薦結果そのものを受け渡さない点が異なる。

Fab[Balabanović 97] は、各利用者ごとに、内容ベースの手法で利用者プロフィール、すなわち、利用者が好むアイテムの特徴を生成する。利用者の類似性をこの利用者プロフィールの類似性で測り、類似した利用者が好むアイテムを活動利用者に推薦する。同様の手法は[Pazzani 99]でも利用されている。

Lee の方法 [Lee 01] は、9・1 節のクラスタモデルの協調フィルタリングで、各クラスタ内のモデルを内容ベースで生成する。

[Yu 03] では階層ベイズに基づく手法が提案されている。活動利用者の嗜好はアイテムの特徴 \mathbf{f} が与えられたときの評価値の事後分布 $\Pr[s_{ij} | \mathbf{f}_j, \theta]$ で予測する。すなわち、内容ベースの枠組みに基づく推薦である。しかし、ここではパラメータ θ の事前分布に無情報事前分布を用いないことでハイブリッド化をする。この事前分布には、利用者 DB の嗜好に依存した分布 $\Pr[\theta | \mathbf{S}]$ 、すなわち、ほかの利用者の嗜好データに基づく協調フィルタリングの要素をもつものを用いる。

§ 7 完全結合 (total integration)

完全結合では、結合される手法に前後関係がなく、ほかの利用者の情報と内容情報とを同等のレベルでモデル化する。

9・3 節の共起型確率モデルでは、アイテムの特徴などを容易に導入できる柔軟性があると述べた。こうした拡張には [麻生 06, 川前 07, Ono 05, Popescul 01, 吉井 06] などがある。一例をあげよう。図 5 (a) の利用者 x とアイテム y だけを考慮するモデルに、アイテムの特徴ベクトル $\mathbf{f} = (f_1, \dots, f_{k_f})$ を導入する場合を述べる。これは式 (10) に新たな項 $\Pr[\mathbf{f}|z]$ を追加して行う。そして、次の同時確率に対する尤度を最大化することでパラメータは学習できる。

$$\Pr[x, y, \mathbf{f}] = \sum_{z \in Z} \Pr[z|x] \Pr[y|z] \Pr[\mathbf{f}|z] \Pr[z]$$




図 8 ハイブリッド型の aspect モデル [麻生 06]

特徴ベクトル \mathbf{f} の要素数が一つであれば、離散値なら多項分布で、連続値ならガウス分布などでモデル化できる。もし要素数が二つ以上であれば、多変量ガウス分布などが利用できる。また、 z が与えられたときに \mathbf{f} の各要素は独立との単純ベイズの仮定のもとで、 $\Pr[\mathbf{f}|z] = \prod_i \Pr[f_i|z]$ などとモデル化してもよい。ただし、 f_i は \mathbf{f} の各要素である。[麻生 06] では、アイテムの特徴 \mathbf{f} に加え、利用者のデモグラフィックな特徴や、利用意図などの特徴 $\mathbf{g} = (g_1, \dots, g_{k_g})$ を加えた図 8 のようなモデルを提案している。式で表すと次のようになる。

$$\Pr[x, y, r, \mathbf{f}, \mathbf{g}] = \Pr[z] \Pr[x|z] \Pr[y|z] \Pr[r|z] \left(\Pr[z_f|z] \prod_i \Pr[f_i|z_f] \right) \left(\Pr[z_g|z] \prod_j \Pr[g_j|z_g] \right)$$

このように、潜在変数を用いた aspect モデルには、推薦に関係するさまざまな要素を自在に導入できる柔軟性がある。モデルを与えれば、EM アルゴリズムによりパラメータを学習できる。いろいろなモデルの中から、集めたテストデータに、機械学習でのモデル選択の手法を適用して、最終的に利用するモデルを最終的に選ばせよう。

もう一つの完全結合の手法として、関数モデルにカーネルを導入する [Basilico 04] の方法を紹介する。この方法では、順序回帰問題に帰着させてモデルを獲得する。利用者 x がアイテム y を好む度合いを次の関数でモデル化する。

$$F(x, y) = \sum_{(x', y')} w(x', y') K((x, y), (x', y'))$$

ただし、 $w(x, y)$ は重みである。そして、しきい値 θ_k について $F(x, y) \in [\theta_{k-1}, \theta_k]$ を満たすなら、利用者 x のアイテム y に与えた評価値は k と予測する。この重み $w(x, y)$ としきい値 θ_k は、順序回帰問題のためのパーセプトロン型の学習則である [Crammer 02] の方法で獲得する。そして、 $K((x, y), (x', y'))$ はカーネル [麻生 03] であり、協調と内容ベースフィルタリングを結合するときには中心的な役割を果たす。この利用者 x とアイテム y の対についてのカーネルは、適当な仮定のもと、利用者とアイテムそれぞれのカーネルの積となる。

$$K((x, y), (x', y')) = K_x(x, x') K_y(y, y')$$

利用者については、 $x = x'$ なら 1、でなければ 0 をとるカーネル、利用者のデモグラフィックな特徴量 $\mathbf{g}(x)$ に基づくカーネル、利用者 x と x' の間の 8・1 節式 (1)

の相関をとるカーネルなどを個々に求め、これらのカーネルの和を $K_X(x, x')$ とする。アイテムについても同様にカーネルを定義できる。この方法では、カーネルを自由に設計できるので、いろいろな要因を考慮した推薦が可能である。さらに、カーネルトリックが適用できるような関数モデルにも適用できるので、多様な応用が可能でもある。

12.2 嗜好の予測手法の選択

嗜好の予測手法のまとめとして、予測手法の選択指針を、私見をまじえつつ列挙しておく。

最初に、協調フィルタリングか内容ベースフィルタリングかの選択について述べる。6.1 節では、両方の手法の長所と短所について論じた。これらのうち、内容ベースにとってはアイテム特徴のデータベースを構築し、維持できるかどうか最大の制約である。この構築・維持コストは、人手を要するため、一般に非常に高い。もう一方の協調フィルタリングでは、嗜好データを収集できるかが大きな制約である。利用者に負担をかけずにその嗜好パターンを巧妙に捉える暗黙的な収集方法か、利用者に評価付けしてもらう良い動機づけが必要になる。これらの両方の制約を満たせるならば、それぞれの長所を生かしたハイブリッドがよいだろう。

2.2 節の運用目的別では、概要推薦であれば、非個人化推薦である人気リストや、直接指定型の内容ベースとなり、利用者評価では、システム側は基本的に場を提供するだけで、予測手法は不要である。関連アイテム推薦では、アイテム間型メモリベースの協調フィルタリングや、アイテムの特徴を用いて関連アイテムを見つけるのが一般的である。通知サービスや緊密な個人化では、個人情報や蓄積していることが前提なので、協調フィルタリングや間接指定型の内容ベースが利用され、予測手法の役割が重要になる。

ここで、**search** と **experience** という推薦対象アイテムの種別 [Senecal 04] について触れておこう。**search** アイテムとは、カタログの規格からの洞察によって、どれを購入するかを選択できるもので、実用品に多い。こうしたものには、基本的には直接指定型の内容ベースを利用する。協調フィルタリングや間接指定型の内容ベースは、順位付けなどのために補助的に利用される。後者の **experience** アイテムは、実際に試さないと判断できないもので、嗜好品などに多い。こうしたものでは、協調フィルタリングでセレンディピティを重視した推薦が有利となる。

次に、8 章～10 章の協調フィルタリング手法の中での選択について論じる。まず最初に、どの手法も背後にいろいろな前提がある。例えば、9.4 節のサブスクリプションを対象とした方法は、推薦ごとに利用者が決定をする通常の推薦には適用できない。各手法の前提に、推薦システムを適用しようとする対象が合っているかどうか

は定性的に検証すべきである。まずおおまかに、データの更新が頻繁ならメモリベースが有利だが、そうでなければモデルベースが高速な推薦が可能である。

メモリベース法には、利用者間型とアイテム間があるが、予測精度よりもほかの規準でどちらかを選択すべきだろう。アイテムの更新が頻繁である場合や、セレンディピティなどについては利用者間型が有利だろう。一方、一時的個人化をしたい場合や、利用者の入換わりが頻繁な場合にはアイテム間型が有利だろう。

次にモデルベース法について述べる。クラスタリングモデルは、非常におおまかな推薦しかできない。新規利用者を対象としたおおまかな推薦が主な利用法だろう。ほかの要因を無視して、予測精度だけを重視するならば、行列分解を用いる関数モデルが、近年の研究では有利であるように著者は思う。確率モデルは、多様な方法が提案されており、いろいろな状況に適応できる。確率モデルの履歴条件型と共起型を比較すると、飽和モデルのパラメータ数はそれぞれ $|X|^m - 1$ と $nm|X| - 1$ となる。よって履歴条件型は、評価値が多段階だったりアイテム数が増えたりすると極端に不利になりやすいが、利用者数には依存しないので、利用者は多いほど高精度のモデルが学習できる。一方、共起型は評価値の段階数、アイテム数、および利用者数のいずれに対しても線形で、破綻しにくいといえる。また、暗黙的な評価値で、未評価と否定的評価が区別できないときには共起型が有利である。時系列モデルは、成長に合わせて購入する製品が変わる子供用品など、時間に大きく依存する場合には有効である。ただし、時刻を考慮する分だけモデルは複雑なので、十分なデータは必要になる。嗜好の揺らぎを考慮する手法もいくつか紹介した。嗜好データに揺らぎがあるかどうかは、5.2 節で述べたように、時間をあけて同じ被験者から嗜好データを集め、整合性が低いかどうかで調べる。

1.1 節で述べたように、あらゆる状況でうまく予測できるアルゴリズムは存在しない。よって、サンプルデータを収集して交差確認法で汎化エラーを実験的に求め、手法を比較したり、パラメータを調整する手続きは不可欠である。調整パラメータ数が増えるアルゴリズムを使ったときには、予測精度の向上がわずかならば、パラメータ数の少ない方法を使っておくか、3.1 節で述べたように、データを訓練・確認・テストに 3 分割した厳密な方法で検証することを薦める。

13. 推薦の提示

本章では、4 章の推薦システムの実行過程の最後の段階である「推薦の提示」についてまとめる。この段階では、予測した評価を、活動利用者の目的に適した形式で提示する。なお、推薦システムの利用者へのアンケート調査結果に基づいて、結果の出力に対する設計指針を、定性

的な面から論じた文献に [Swearingen 01] がある。推薦したアイテムに関する情報も提示すべきことや、推薦リストのレイアウトや、これを閲覧するインタフェースの重要性などを指摘している。

13.1 推薦の配送

利用者に推薦結果を届ける手段は、次のように分類できる。

push 型 利用者が、システムを直接には使っていない場合に、利用者に推薦を届ける。個人化していないバナー広告や、個人化したメールマガジンなどが該当する。

pull 型 システムを使用中の利用者が要求したときに、それに応じて推薦結果を届ける。検索質問を使う直接指定型の内容ベースフィルタリングの推薦は、この方法を用いる。

passive 型 利用者がシステムを使用中に、推薦結果を添付しておく。例えば、商品とともに推薦の度合いを★印で示したり、関連商品を同時に示したりする。利用者に主導権があり、システム側は積極的な推薦はしない。

2.2 節の 5 種類の運用側の目的のうち「通知サービス」では **push** 型を、ほかの目的では **pull** 型か **passive** 型を利用することになる。

その他、配送するかどうかの決定についての工夫もある。マイクで獲得した発話内容から、視聴中のテレビ番組への関心の度合いを推定し、関心が低いと推定されたときにのみ積極的に推薦をする方法 [高間 07] などが提案されている。

13.2 推薦アイテムの選別

予測評価の高いアイテムでも、推薦すべきでないアイテムがある。そういったものを必ず選別し除外しておく必要がある。

利用者が既知であるとわかっているアイテムを推薦してもほとんど意味がないので、これらのアイテムを除外する。例えば、同じセッション中ですでに提示したアイ

テムや、購買履歴から過去に購入したことがあるものなどを除外する。また、非個人化推薦である売上げランキングなどを同時に表示する場合は、重複したアイテムを除外しておくほうがよいだろう。[清水 07] では、利用者から、アイテムへの好き嫌い評価だけでなく、既知かどうかの情報も得る。その情報に基づいて、利用者がアイテムを既知かどうかも予測し、未知と予測されるアイテムをより積極的に提示する。

その他、アイテム、デモグラフィック、およびコンテキストの情報に基づいた除外も必要になる。例えば、アイテムに依存した条件としては、在庫がないとか、利用者が海外在住で発送できない理由で提供できない商品がある。当然ながら、違法なアイテムも除外すべきである。また、色違いなど差異がわずかなものは、代表的なものを一つだけ残して、残りは提示しないといったことを行う。デモグラフィックな特徴は、女性専用の旅行プランは男性には推薦しないといったことに利用できる。また、コンテキストの情報に関しては、利用者の現在位置から遠いレストランは推薦すべきではないし、夏に冬物衣料を推薦すべきではないといった季節商品の問題もある。

13.3 推薦の表示形式

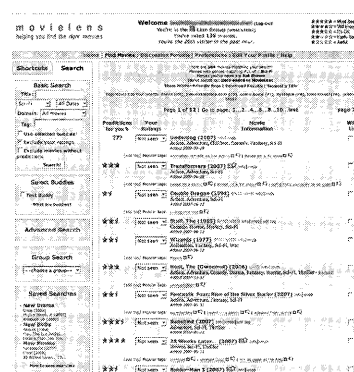
推薦すべきアイテム群を表示する形式は、2.3 節の利用者の目的に応じて以下のように適切なものを選択すべきである。

適合するものを一つ見つけ出す適合アイテム発見を目的とする場合には、予測される評価の高いものから順に整理したリストを利用者に提示するのが一般的である (図 9 (a))。利用者はこのリストを上位から閲覧することで、自分の嗜好に適合したアイテムを素早く見つけることができる。

評価閲覧を目的とする利用者は、積極的な決定をする意図をもっていない。そこで、閲覧中のアイテムに、活動利用者の予測評価値を付随的に提示する。これは、★の数や、アイコン、グラフなどで表す (図 9 (a))。このよ



(a) 適合アイテム発見 (Amazon.co.jp*)



(b) 評価閲覧 (MovieLens[MovieLens])

図 9 推薦結果の表示例

*1 スクリーンショットは 2007/07/26 に取得した。

うな情報を参照することで、多数の候補の中から、利用者にとって関心のあるものを中心に閲覧できるようになる。

13.4 セレンディピティの向上

評価閲覧 (2.3 節) を目的とする場合は、利用者の関心の幅を広げるため、セレンディピティ (3.1 節) の高い推薦が望まれる。そこで、[Ziegler 05] ではセレンディピティを向上させる目的で、予測精度を犠牲にしても、より広範囲の分野のアイテムを推薦する話題多様化 (topic diversification) を提案している。具体的には、アイテムの階層的な分類を導入し、分類階層の近さによってアイテム間の類似度を測る。純粋に予測精度を重視したリストの上位から順に、最終推薦リストにアイテムを一つずつ追加するが、このとき、すでに推薦したアイテムと類似しているアイテムは推薦されにくいようにする。この方法により、予測精度を犠牲にして、アイテムの多様性をより重視するような推薦をする実験を行った。予測精度を単調に減少させ、徐々に多様性を高めると、最初は利用者は推薦の多様性の高まりを認知できたが、ある程度以上になると認知できなくなった。よって、推薦リストの多様性を利用者が認知できる程度にとどめれば、予測精度もそれほど低下せず、利用者の満足は高まると報告している。その他、推薦リストに、新製品やあまり知られていないアイテムを必ず混ぜるといった手法も考えられる [Swearingen 01]。

13.5 推薦理由


利用者は、不必要に高価なものを薦められていると疑ったりするため、推薦したアイテムを必ずしも採用するわけではない。採用されない推薦は無意味なので、推薦ができるだけ採用されるような工夫が必要である。そうした工夫として、アイテムの推薦理由も示すことが有効とされている。

[Sinha 02] では、推薦の透明性と利用者の推薦結果に与える印象との関係を調査している。ここでいう透明性とは、利用者の入力した評価やその他の情報と、出力された推薦との間の因果関係が明確に説明されていることである。この調査では、12 人の被験者に 5 種類の商用音楽推薦システムを利用させた。そして、推薦されたアイテムを好むか、推薦は信頼できるか、そして推薦に透明性があったかの質問をした。調査の結果は、透明性があると考えた場合のほうが、そうでない場合に比べて、有意に推薦された結果を好み、また、その結果を信頼できると答えた。さらに、推薦されたアイテムを、(a) 知らない場合、(b) 知っていてかつそれを好きな場合、および (c) 知っていてかつそれを嫌いな場合に分けた。推薦されたアイテムを好むかどうかの質問については、(b)、(a)、(c) の順に好んだ。さらに、(a) と (b) の推薦については、推薦に透明性があると、ないときよりも、有意に推薦されたアイテムを好んだ。しかし、(c)

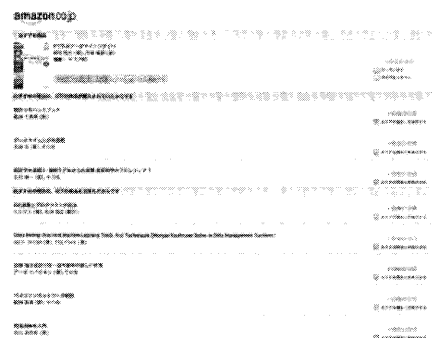
の推薦については、有意な差はなかった。これらのことから、利用者が推薦に透明性があると考えたときには、推薦されたものをより好み、その推薦を信頼する。また、知っている好きなアイテムを推薦されると、推薦に透明性があると利用者は考えるといえる。なお、実際がどうであるにかかわらず、透明性があると考えたかを利用者に質問した結果であること、また、システムがデータをねつ造していない点については、利用者はシステムを信頼していることには注意されたい。利用者もおそらく知っているであろう、一般に知られたアイテムを推薦して、利用者の推薦への信頼を向上させるといったこともできる [Swearingen 01]。

推薦の透明性を高める、すなわち、利用者が入力した嗜好データから、推薦を導いた根拠を明示することで、推薦への信頼を高める試みがある。[Herlocker 00] では、こうした根拠を提示する手法を比較している。その中で最も有効な方法とされたのが図 10 (a) の方法である。これは、活動利用者と類似した嗜好をもつほかの利用者の、推薦した映画についての評価値を棒グラフで示したものである。この例では、推薦した映画について、嗜好が似ている人達のほとんどが、最高かそれに次ぐ評価をしていることが一目でわかる。その次に有効であったのは、推薦の確信度を示すことである。ここで、推薦の強さ (strength) と確信度 (confidence) について述べておこう。推薦の強さとは、どれくらいアイテムを好むと

Ratings for *Sixth Sense, The (1999)* by your Neighbors



(a) 類似した嗜好の利用者の評価の提示 [Herlocker 00]



(b) 推薦の根拠となった嗜好データの提示 (Amazon.co.jp *1)

図 10 推薦根拠の提示例

*1 スクリーンショットは 2007/07/26 に取得した。

予測しているかということである。利用者の嗜好を5段階で予測するなら、5と予測したときに強い推薦といえる。一方の推薦の確信度とは、この推薦をどれくらい確かだと考えているかということである。9・3節の確率モデルで、適合・不適合の2段階で活動利用者の嗜好を予測したとしよう。このとき、適合すると予測した確率が0.6でも0.9でも予測は「適合」だが、後者のときにより確かな推薦といえる。さらにほかの方法でも実験したが、利用者の満足を上させた方法はなかったと報告している。

その他、8・2節のようにアイテム間の類似度に基づく推薦では、推薦に関連したアイテムを提示する方法もある。図10(b)は、活動利用者自身の、推薦の根拠となったほかのアイテムへの評価を提示したものである。また、暗黙的に嗜好データを獲得した場合、推薦の根拠を利用者が認知できなくなるので、推薦とともに根拠となった嗜好データを示す方法もある。ただし、予測評価値などを提示して、利用者が嫌いなアイテムが高評価されていると、システムに対する信頼を失う危険性も指摘されている [Swearingen 01]。

14. その他の問題や視点

その他の視点に関する研究をまとめて述べる。

14・1 対話型システム

これまでの推薦システムは、過去に入力された嗜好データに基づいて利用者の嗜好を予測し、一度だけ推薦の提示を行う。だが、利用者がその推薦に満足できない場合がある。そうした場合に、活動利用者からフィードバックを得て、その情報を用いてより適切な推薦をする対話的な推薦も研究されている。フィードバックは、アイテムへの評価値を返すアイテムレベルと、アイテムの特徴を指定する特徴レベルとに分けられる。これらを順に紹介する。

§1 アイテムレベルのフィードバック

機械学習のクラス分類の訓練事例では、ラベル付けされている事例の特徴ベクトルは受動的に決められているのが一般的である。そうではなく、能動的に都合の良い特徴ベクトルをもつような事例を指定すると、それに対するラベル情報が得られる状況を扱うのが能動学習 [渡辺 05] である。この枠組みを導入し、推薦の予測精度が不十分だった場合に、推薦を改善するのに役立つであろうアイテムを利用者に評価してもらうことが考えられる。では、どのアイテムを評価させるのがよいだろうか？ 直観的に、利用者によって評価にばらつきがあり、好みの分かれるアイテムを評価してもらうのはよいだろう。この考えに基づいて、ほかの利用者の評価値の分散やエントロピーが大きなアイテムを選ぶ方法が提案されている [Kohrs 01]。[Boutillier 03] では、アイテム選択の尺度として、

期待情報価値 (Expected Value Of Information: EVOI) を提案している。まず、現在の嗜好データで予測したとき、期待的に最も良い評価値は、全未評価アイテム上での、期待評価値の最大値である。ここで、未評価アイテムの一つ x_q に対する評価値を利用者から得ると、この最大期待評価値は変化するはずである。だが、どのような評価値を利用者が返すかはわからないので、評価後の最大期待評価値の、評価値定義域 \mathcal{Q} 上の期待値を考える。この期待値から、評価前の最大期待評価値を引いた値を EVOI とする。すると、EVOI は、利用者からアイテム x_q に対する評価値を得たことによる、最大期待評価値が改善する量を表す。よって、この EVOI を最大にする未評価アイテムを活動利用者に評価してもらえばよい。だが、実際には計算量が多いため、この EVOI の値の代わりにその上限を計算して代用する。その他、候補アイテムの評価値が予測どおりであったときと、それとは若干ずれた値であったときの、ほかの未評価アイテムの予測評価値の変化の大きさが大きいアイテムを選ぶ方法も提案されている [Rubens 07]。この能動的評価の問題点は、利用者が任意のアイテムをすぐに評価できなければ適用できないことである。例えば、音楽であればその場で聞かせて評価させることができるが、映画や書籍の場合では難しい。

純粋な協調フィルタリングでは、コンテキストの情報 (5・5 節) を利用できない。また、コンテキスト自体を特徴として明示することが困難な場合がある。そこで、[Rafter 05] は嗜好データを長期と短期のプロファイルに分けて考える手法を提案している。長期プロファイルとは、現在の推薦のセッションより以前に入力された嗜好データで、利用者の基礎となる嗜好パターンを表しているとみなす。一方、現在のセッションで提示した推薦リスト中のアイテムに対する嗜好データが短期プロファイルで、現在のコンテキストでの嗜好を示しているとみなす。フィードバックは、目的のアイテムに近いものや、全く当てはまらないものを利用者に指定させる。予測には利用者間型のメモリベース法 (8・1 節) に基づく。長期プロファイルに基づいて活動利用者と標本利用者の間の類似度を計算する点は同じである。しかし、フィードバックで肯定的だったアイテムを好み、そうでないものを嫌うような標本利用者を重視するように、標本利用者を重み付けする。このようにして、短期プロファイルに暗黙的に示されたコンテキストを反映する推薦が実現される。

[Smyth 03] は、対話的な推薦で、候補アイテムが適切に絞り込まれているかを検証する方法を提案している。アイデアは非常に簡潔で、前回の推薦で肯定的なフィードバックが与えられたアイテムを、次の推薦リストに混ぜておく。もし混ぜておいたそのアイテムが再び選択されるようならば、絞り込みは適切でなかったと判断し、ほかの方向からの絞り込みに変える。そうでな

ければ、同じ方向で絞り込みを続ける。

§2 特徴レベルのフィードバック

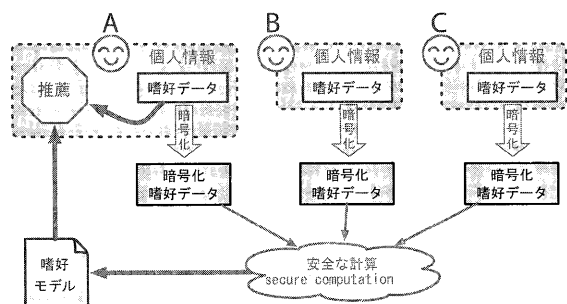
特徴レベルのフィードバックは、アイテムの特徴を扱うため、内容ベースフィルタリングが対象となる。この種のフィードバックでは、推薦されたアイテムを見て、アイテムの望ましい性質を利用者が示す。例えば、パソコンではメモリが1GB以上といった、アイテムの特徴に対する条件の精細化をする。11章で述べたように、内容ベースの推薦は情報検索と類似しているの、情報検索でフィードバックを扱う手法が、内容ベースの推薦に応用できる。情報検索では、検索質問と関連する語を利用者に提示し、利用者がそれを選択することで、検索質問拡張を実現するものがある。これと同様の手法が、推薦システムでも利用されている [Smyth 04]。

その他、[McSherry 05] では、13.5節のように、説明を導入してより円滑に対話的な推薦を行うことを提案している。ある特徴レベルフィードバックを利用者が返すと、次の推薦で候補の数や内容がどのように変わるのかを簡潔に説明し、より適切なフィードバックが得られるようにしている。

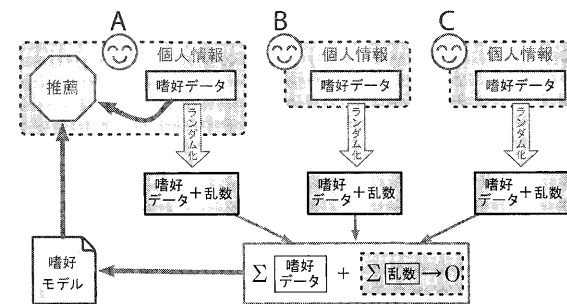
14.2 プライバシー保護協調フィルタリング

協調フィルタリングでは、標準利用者の嗜好データを収集する。このデータが、商品の購入履歴などであった場合は、これらの情報は利用者が秘匿したい個人情報となるであろう。さらに、断片的な情報を集積することで、より重大な個人情報を得ることもできるようになってきている。例えば、Sweeney は、87%のUS 在住者が、性別、5桁郵便番号、生年月日の情報だけで一意に特定できることを示した [Sweeney 00]。映画の評価について、掲示板発言と、これとはまた、独立した推薦システムの評価データのパターンの類似性から、匿名の利用者のIDの対応付けがかなりの割合でできることも示されている [Frankowski 06]。現在では、プライバシーは「個人が自らの情報を自分でコントロールできる権利」[沼尾 06]を意味するようになり、ますます重視されるようになってきている。一方、協調フィルタリングはこうした個人情報なしには実現できないので、これらの情報を収集する必要がある。

現状では、この個人情報の収集に伴う問題には、プライバシーポリシーを公開し、それを遵守することを誓約することで、社会的手段によって対処している。これに対し、技術的手段によってこの問題に対処するのがプライバシー保護協調フィルタリング (privacy-preserving collaborative filtering) である。プライバシー保護協調フィルタリングの技術は、プライバシー保護データマイニング (privacy-preserving data mining) [Vaidya 05]^{*2}と関連が深い。これは、分散環境の各サイトに分割されて



(a) 安全な計算による方法



(b) ランダム化による方法

図11 プライバシー保護協調フィルタリング

保持されているデータがあるとき、それらすべてを集めたデータ集合に対するデータマイニング結果を、各サイト内のデータの内容を自分以外のサイトは秘密にしたまま計算する技術である。この計算を実現するアプローチとしては安全な計算 [Lindell 00] とランダム化 [Agrawal 00] とを使う方法がある。プライバシー保護協調フィルタリングにおいても、この二つのアプローチがある。これらを順に説明する。

§1 安全な計算による方法

モデルベースの協調フィルタリングでは、標準利用者の嗜好データではなく、それらの規則性を表したモデルさえあれば推薦が可能である。よって、嗜好データそのものを知らせることなくモデルが構築できれば、プライバシーの問題は生じない。また、メモリベースの協調フィルタリングでも、次元節約を導入すれば、個々のアイテムへの評価値は秘匿できる。これを、データを暗号化したまま計算する安全な計算 (secure computation) [Clifton 02]^{*3} と呼ばれる技術によって実現する。

このアイディアに基づく枠組みを図11(a)に示す。まず、標準利用者は自身の嗜好データを暗号化して推薦システムに渡す。ここで、渡されたデータは暗号化されているため、個人情報は外部には漏れない。これらの暗号化嗜好データに、安全な計算の技術を適用して、暗号化された状態のモデルを獲得する。最後に暗号化モデルを復号して目的の嗜好モデルを得る。ここで、この嗜好

^{*2} C. Clifton のホームページ [Clifton] の解説を参考にされたい。

^{*3} secure computation には『秘密計算』という訳語もある。だが、ここではデータが秘匿されるだけでなく、計算の結果が正しいことも考慮に入れるという意図で『安全な計算』としておく。

モデルは標本利用者全般の嗜好の規則性の情報を表しているが、このモデルから個々の標本利用者の嗜好データ自体を復元することはできない。よって、個人情報漏洩にはならない。活動利用者は、自身の計算機上で、このモデルと自身の嗜好データから推薦を得ることができる。モデルには、利用者間型メモリベースで次元縮約を使うもの [Canny 02a] や、9.2 節の行列分解を使うもの [Canny 02b] などがある。

しかし、現状のプライバシー保護協調フィルタリングでは、社会的手段が補助的に必要となる。計算結果が改ざんされていないかを検証するには、半数以上の参加者は、個人情報を明かすほど信頼はできないが、計算の手続きは遵守する程度には信頼できるという semi-honest という前提が必要である。しかし、この前提の技術的手段による保証は難しく、社会的手段によって保証しなければならない。そのため、匿名で参加できる peer-to-peer ネットワークなどでの実現は難しい。ソーシャルネットワークなど個人認証がなされるサービスでの推薦や、複数の企業が自身の顧客の情報を秘匿しつつ、共同して推薦をしたい場合などを想定すべきである。

§2 ランダム化による方法

安全な計算は、暗号化はしているが、個人情報の真の値を外に出している。そうではなく、真の値ではない値を外に出す方法がランダム化 (randomization) による方法 (図 11 (b)) である。

原理は単純で、平均値が 0 の正規分布や一様分布に従う乱数を加えてから、自分のデータを外部に出力する。このとき、全参加者は同じ確率分布から独立にサンプリングした乱数を用いることが重要である。ここで、全参加者の出力した値の総和や内積を求める。この値は、真の値の総和に、乱数の総和を加えたものになっている。ここで乱数の総和は、大数の法則により、もとの分布の平均である 0 に漸近的に近づく。よって、十分な数のデータがあれば、総和や内積が近似的に計算できる。この手法によるプライバシー保護協調フィルタリングは [Polat 03] などで提案されている。この方法は、真の値は外部に出さなくて済む利点があるが、加える乱数の標準偏差が小さいと、真の値が近似的に予測できてしまったり、厳密な値ではなく近似値しか計算できないといった欠点がある。

14.3 サクラ攻撃

推薦システムの効用について考えてみよう。利用者は知りたい情報を入手できるようになり、システムに満足するだろう。これにより、システムの運営者には、システムが利用が促進されるという利点がある。では、利用者に推薦される製品や情報の提供者にとってはどうか？ 自身の製品の代わりに競合他社の製品が推薦されてはしくないとか、たとえ自社の製品が推薦されていても、さらに推薦されるよう望んだりするだろう。こ

れらの要求は必ずしも満たされるとは限らないため、推薦結果を自身に有利にする目的で推薦システムに干渉することが行われ始めている。具体的な事例は [Lam 04] を参照されたい。

こうした行為の一つにサクラ攻撃 (shilling attack) がある。これは、サクラボット (shilling bot) と呼ばれるエージェントプログラムや、雇った人間に、自身に有利な推薦がほかの利用者になされるように、推薦システムへ嗜好データを入力させるものである。サクラ攻撃は、利用者にとっては不適切な推薦がなされるため望ましくない。運営者にとってもシステムへの信頼を失わせる行為であるため、サクラ攻撃は排除すべきものである。サクラ攻撃の有効性の検証や、攻撃検出などの対策は、[Lam 04, O'Mahony 04] などによって研究が始められた。サクラ攻撃全般についての良いまとめとしては [Mobasher 07] がある。以下、サクラ攻撃の構成要素、攻撃戦略の体系的な分類、攻撃への対策を紹介する。

§1 サクラ攻撃の基本

サクラ攻撃の基本事項をまとめる。

攻撃意図とは、攻撃の実行者が推薦をどのようにに変化させたいかという目的である。

- 販促攻撃 (push attack) : 本来なら推薦されないはずの、自社の製品などのアイテムを推薦されるようにする。
- 排除攻撃 (nuke attack) : 本来なら推薦されるはずの、他社の競合製品などのアイテムを推薦されないようにする。
- 攪乱攻撃 (random attack) : 予測精度を下げさせて、システムへの信頼を失わせる。

このうち前者二つの攻撃目的について研究がなされている。こうした攻撃は、一部の限定された利用者やアイテムに対して集中的に行われる。

一般に、大量の情報、またシステムに密接な情報を利用した攻撃ほど効果的な攻撃が可能になる。特に、利用者の嗜好データに完全にアクセスできると、検出はほぼ不可能である。しかし、この種の情報は、プライバシー保護の観点からも厳重に管理されているため、攻撃者が合法的に入手するのは困難である。比較的容易に合法的に入手できるデータとして、アイテムへの平均評価値がある。これらのデータを公開しているシステムや、利用者そのものでなくても、コメントを付けている編集者や利用者の評価の平均値を出しているものは多い。さらに映画における IMDB [IMDB] のように、アイテムの評価サイトから、代替情報を別途入手できる場合もある。また、推薦アルゴリズムごとに効果的な攻撃の作戦があるので、使っているアルゴリズムの情報も重要である。一時的な推薦を協調フィルタリングで行うには、アイテム間型のメモリベース手法が多用されるといったことを用いて、この情報もある程度推定できる。

サクラ攻撃の効果は次のような指標によって測る。

- 予測シフト (Prediction Shift) : 攻撃の前後での、予測評価値の変化の全標的アイテム (後述) と全利用者についての平均。予測評価値自体がどれくらい攪乱されたかを測るための指標である。
- ExpTopN (Expected Top-N Occupancy) : 上位 N 個の推薦アイテムに標的アイテムが含まれる個数の、全利用者についての期待値。評価値が変化しても、アイテムの順位に影響するとは限らないので、実際の推薦リストの変化を測るための指標である。

§2 サクラ攻撃の種類

次に、攻撃の方法について述べよう。サクラボットなどに入力させる嗜好データのことを攻撃プロファイル (attack profile) という。この攻撃プロファイルは、2 種類のアイテム群への評価値で構成される。一つは標的アイテム (target item) と呼ばれる。販促攻撃の場合はより推薦されるように、排除攻撃では推薦されないようにしたいアイテム群である。サクラ攻撃の発覚を防ぐため、これらのアイテムは少数に限定する。サクラボットは、販促攻撃ではこれらのアイテムに過剰に高い評価値を、排除攻撃では過剰に低い評価値を与える。

しかし、これだけでは効果的な攻撃はできない。協調フィルタリングでは、嗜好が似ている利用者を参考に推薦することを思い出されたい。標的アイテムだけを評価したプロファイルは、ほかの利用者の嗜好パターンと似ていないことが多いため、こうしたプロファイルは推薦結果に影響しない。そこで、ほかの利用者の嗜好パターンに攻撃プロファイルを似せるため、標的アイテム以外のアイテム群にも評価値を与える。これらのアイテムを詰め物アイテム (filler item) と呼ぶ。この詰め物アイテムにどのような評価値を与えるかによって、次のように攻撃方法がある。

- サンプリング攻撃 (sampling attack) : 詰め物アイテムに、システムのデータベースからサンプリングしてきた評価値を与える。統計的手法では検出は不可能といってよいが、システム内のデータベースの情報の入手は非常に困難である。
- ランダム攻撃 (random attack) : ランダムな評価値を、詰め物アイテムに与える [Lam 04]。必要な情報は無いが、あまり効果はなく発覚しやすい。
- 人気商品攻撃 (bandwagon attack) : 良く売れている人気商品の評価は高いことが多く、また多くの利用者が評価している。このことを利用し、人気商品に高い評価値を与えて、攻撃プロファイルのほかの利用者への類似性を高める [O'Mahony 04]。
- 平均攻撃 (average attack) : 詰め物アイテムに、それらのアイテムへの評価値の平均値を与える [Lam 04]。アイテムへの平均評価値は入手が比較的容易だが、利用者間型のメモリベース手法には効果的である。一方、アイテム間型では、予測シフトで評価すると確かに評価値には影響するが、推薦リス

ト中でのアイテムの順位を変えるまでには至らず、ExpTopN への影響は限定的である。

- 探査攻撃 (probe attack) : ダミー利用者をつくり、その利用者に推薦されたアイテムの予測評価値を詰め物アイテムへの評価値とする [Mobasher 07]。ダミー利用者と類似した嗜好の利用者にのみ有効な攻撃である。
- セグメント攻撃 (segment attack) : 映画のジャンルなど、アイテムの分類情報が利用できる場合の販促攻撃に用いる [Burke 05]。標的アイテムと同じセグメント (分類カテゴリー) のアイテムには、高い評価を与える。同じセグメントのアイテムには、同じような評価がなされやすいという傾向を使う。アイテム間型のメモリベースに対して有効な攻撃である。
- 愛憎攻撃 (love/hate attack) : 排除攻撃専用の手法。標的アイテムには最低の評価を、詰め物アイテムには最高の評価を与える [Burke 06]。単純な攻撃だがアイテム間型と利用者間型のどちらのメモリベース手法についても効果がある。

§3 サクラ攻撃に対する防御

作為的な利用者の評価に影響されて、協調フィルタリングが不適切な推薦をしたとしよう。そして、ほかの利用者がその推薦に従ったとしても、その後、作為のない評価をするので、自律的にこうした攻撃は無力化されるとも考えられていた。しかし、Cosley ら [Cosley 03] はこれに対して否定的な調査結果を報告している。以前に評価したことのあるアイテムについて、以前と同じ、1 段階良い、1 段階悪いの 3 種類のものを「予測評価」と偽って利用者に提示した。すると、作為的にずらした方向に、アイテムへの利用者の評価が変化した。さらに、未評価のアイテムについて、アルゴリズムができるだけ正確に予測した評価、それより 1 段階良い・悪い評価を利用者に提示すると、やはり、同様の傾向が見られた。このように、心理学における同調 (conformity) [中島 99] と類似した、周りの意見に利用者の意見が「引きずられる」現象が報告されている。そのため、サクラ攻撃に対して推薦システムは自律的に回復することはできず、攻撃を検出して排除する必要がある。

サクラ攻撃は、サンプリング攻撃以外は、真のデータベースの評価値分布と、攻撃プロファイルとの統計的な分布の差をはずれ値検出の技術によって見つけることで検出する。[Zhang 06b] の方法は、最も基本的なもので、モデルから予測される評価値と、実際の評価値の差が標準偏差に対して十分に大きければ攻撃とみなす。ランダム攻撃は比較的容易に検出できるが、平均攻撃では失敗することもあり。また、サクラボットが評価するアイテム数が少ない場合や、標的アイテムが多い場合は検出が困難になると報告している。[Burke 06] では、アイテムに対する平均的な評価からの乖離を、被評価数などで

加重した統計量や、ボットの攻撃は多数のアイテムに対して行われることを利用した統計量を提案している。加えて、平均攻撃など特定の攻撃に対する検出方法も検討している。その他、攻撃が特定の時期にまとまって行われることが多いことを利用し、時系列中での検出を試みる研究 [Zhang 06a] もある。これは、あるアイテムについての評価値を、一定間隔の期間ごとに分ける。そして、各期間内の評価値の平均やエントロピーが異常値になることを検定により検出する。

14・4 標本利用者の選別

協調フィルタリングでは、ほかの標本利用者の意見を参照する。このとき、嗜好が似ているだけでなく、該当分野に詳しい利用者の意見を参照するほうがよいだろう。こうした試みは、協調フィルタリングが自動化される以前からある [Kautz 97]。

自動化された協調フィルタリングで、標本利用者を目的に応じて選別するアイデアには次のようなものがある。ある標本利用者の嗜好データから、いろいろな活動利用者の評価値を予測する。このとき、より多くの活動利用者の評価値を正確に予測できたとすれば、その標本利用者はほかの活動利用者の評価値予測にも有用だろう。文献 [O'Donovan 05] は、このアイデアに基づいた標本利用者の重み付けを提案している。[亀井 04] では、各利用者が個別に文書レポジトリを所有しており、そのレポジトリは公開されている状況を想定する。各文献を特徴ベクトルで表現し、活動利用者の評価とある標本利用者のそれが類似しているとき、その文献に関連した特徴に関して、その標本利用者は信頼できると考える。そして、それと同じ特徴をもつ文献に対する評価では、その標本利用者の意見を重視する。あるカテゴリーのアイテムを、より多く評価している利用者は、そのカテゴリーのアイテムについて詳しいと仮定してよいだろう。このアイデアに基づき、[Cho 07] では、評価値を予測しようとしている目標アイテムと同じカテゴリーのアイテムを多数評価している標本利用者の意見を重視することを提案している。

14・5 推薦システムの運用

その他、推薦システムの運用に関係する問題についてまとめておく。推薦システムを含めたフィルタリング技術の法的側面からの問題点を述べた解説としては [新保 06] がある。著名な推薦システムの内部アルゴリズムを概説した文献をあげておく：オンライン小売りサイト Amazon.com [Linden 03]、ニュースの要約サイト Google News [Das 07]、学術文献検索サイト CiteSeer [Lawrence 99]、推薦機能付きセットトップボックス TiVo [Basu 04]。稼働中のシステムの運用に関する情報として、書籍販売サイト bk1 での推薦エンジン AwarenessNet [市川 07] や、携帯向け映画推薦システムのストリートキャッチ方式に

よるアンケート調査 [小野 07] の結果などがある。

次に、推薦システムに関連の、マーケティング分野の研究について述べる。まず、簡単な市場モデルを示した研究をあげる。[Fleder 07] では、推薦システムが顧客の購入行動に影響を与え、市場の寡占化が生じるかを 2 個のアイテムがある市場の数値モデルで論じた。購入したことを肯定的、購入しないことを否定的な評価としたとき、購入されたアイテムは推薦されやすくなり、寡占化が進む場合が多い。そうならないのは、顧客が推薦を受ける以前は一方のアイテムを強く好んでいるが、推薦にも影響されやすいという状況だけに限られる。[Bergemann 06] では、1 回目に一方の店で購入すると推薦を受けられるが、他方の店で購入すると受けられないモデルの均衡状態を求めている。このモデルで、推薦を受けられることの付加的な価値が、二つの店舗のシェアや顧客が購入するアイテムに与える影響を論じている。推薦の正確さと、好みのほうの商品を選択することが顧客にとってどれくらい重要であるかによって、4 種類の異なる均衡状態があることを示している。

次に、推薦が顧客の意思決定に与える影響をアンケート調査した研究を示す。[Senecal 04] では、仕様だけで好みの判断ができる search 型の商品群と、試さないと判断できない experience 型の違いについて調査し、experience 型の商品群のほうがより推薦に従うと報告している。ほかの顧客の推薦より、推薦システムは信頼されていないにもかかわらず、実際の影響は推薦システムのほうが強かったとも報告している。また、販売業者から独立した組織の推薦であるかどうかは、信頼性や意思決定に影響しないことを報告している。顧客はまだ知らないアイテムを推薦するとき、同時に提示する情報の影響について [Cooke 02] は報告している。顧客が好きなアイテムを同じ画面でともに示すと、知らないアイテムも同様にみなされて好まれる。だが、この効果は、別画面に表示するだけで失われてしまう。知らないアイテムに固有の情報を与える（サンプル曲を聴かせるなど）と、差異が意識され、知らない推薦への魅力が下がるとも報告している。なお、これらは実際のシステムの推薦ではなく、推薦システムからの出力であることにして被験者に示した場合の調査結果である。

推薦システムによって、利用者の嗜好を逆転させることは、上記のような研究に加え、[Cosley 03] でも指摘されている。だが、こうした行為を長期的に継続したときの影響は調査されていない。著者は、推薦システムは [Ben Schafer 01] にもあるように販売側ではなく、顧客側に立つことは必要な条件だと考えている。なぜなら、こうした利用者の嗜好のねじ曲げは、長期的には推薦システムへの信頼を損なう危険が多いだろう。こうしたことをせず、利用者の意向に沿うことに徹しても [Ben Schafer 01] にあるような三つの効用があるだろう。第 1 に、顧客が真に好むものを積極的に提示するこ

とで、閲覧者を購入者に変える。第2に関連商品を推薦して **cross-sell** を増加させる。最後に、顧客側の推薦を続けることによって長期的な顧客ロイヤリティを構築する。推薦システムは、どんなに売れない商品を買ってしまう魔法の杖ではなく、逆に売れ筋商品の寡占を加速する場合もあることは意識しておくべきだろう。

15. 参考資料の紹介

推薦システムや協調フィルタリング全般についての参考文献をあげておく。推薦システムの位置づけを含めた全般については [Ben Schafer 01] が良いだろう。[Herlocker 04] では、「良い推薦とは」ということに深い考察がなされており、本格的に推薦システムに取り組む前に一読することを薦める。協調フィルタリングの初期アルゴリズムの比較実験としては [Breese 98] が著名である。比較的近年の手法をまとめたサーベイには [Adomavicius 05] がある。ハイブリッド手法については [Burke 02] にまとめられている。推薦システムの特集には [Felfernig 07, Konstan 04, Resnick 97] などがある。日本語の解説もあげておく。[神寫 06] を含めた特集 [川瀬 06] には、有害情報のフィルタリングと表現の自由など法的観点から、推薦システムの概要まで情報フィルタリングについて幅広く述べられている。情報処理学会誌の特集 [土方 07a] には、推薦システム全般について簡潔にまとめた [土方 07b] や [神寫 07a] に加え、いくつかの実システムについても述べられている。単独記事としては、ユーザプロファイリングを中心にした [土方 04] などがある。

関連資料を入手できるサイトとしては以下のようなものがある。

- GroupLens プロジェクト
<http://www.grouplens.org/>
 MovieLens の実験システム、プロジェクトの参考文献、代表的なテストデータなどを参照できる。
- ACM Recommender Systems
<http://recsys.acm.org/>
 2007 年から始まった推薦システムの国際会議
- Joseph A. Konstan
<http://www-users.cs.umn.edu/~konstan/>

表7 検索エンジンのソースコードの配布 WWW サイト

consensus	http://exogen.case.edu/projects/consensus/
Vogoo	http://www.vogoo-api.com/
SUGGEST	http://glaros.dtc.umn.edu/gkhome/suggest/overview
CoFE	http://eecs.oregonstate.edu/iis/CoFE/
Taste	http://taste.sourceforge.net/
Duine	http://sourceforge.net/projects/duine
BlogLens	http://sourceforge.net/projects/bloglens/
Slope One	http://www.daniel-lemire.com/fr/abstracts/SDM2005.html
Colfi	http://sourceforge.net/projects/colfi
C/Matlab	
Toolkit for CF	http://www.cs.cmu.edu/~lebanon/IR-lab.htm

チュートリアル の発表資料が多数配布されている。

アルゴリズムを検証するために利用できるベンチマークデータを表6にあげておく。なお、推薦システム研究の初期によく利用された、映画評価データ **EachMovie** もあるが、現在は配布が停止されているので、これを利用するのは避けたほうがよいだろう。また、ソースコードが公開されている推薦システムエンジンには表7のようなものがある。

16. 推薦システムの課題

最後に、著者の私見ではあるが、推薦システムの研究課題を、推薦の品質と運用面からあげておく。

16.1 推薦の品質

推薦アルゴリズムの予測精度の向上は、すでにほぼ飽和状態にあるといってよいだろう。絶対的に予測精度が高いアルゴリズムはなく、相対的な優劣は、アイテム数と利用者数との比率などデータの性質に依存している [Herlocker 04]。今後は、予測精度以外の規準も考慮し、利用者の要求をよりの確に捉えることに注目すべきだろう [McNee 06a]。この方向での改良点をあげる。

このためにまず必要となるのは、予測精度以外の評価指標だろう。こうした多様な規準の必要性は [McNee 06b] などで指摘されている。こうした基準には、アイテムの特徴 [Ziegler 05] や、単純な予測器 [村上 07] を用いた意外性の規準がある。また、全利用者について推薦されるアイテムの種類の分布の Gini 係数を用いて推薦

表6 テストデータの配布 WWW サイト

http://www.grouplens.org/node/73#attachments	映画推薦システムMovieLens (最もよく使われているベンチマーク)
http://www.netflixprize.com/	ビデオレンタルNetflix (賞金付きで話題に)
http://www.ieor.berkeley.edu/~goldberg/jester-data/	アメリカンジョークの推薦システムJester
http://www.kamishima.net/sushi/	採点法と順位法による寿司の嗜好アンケート
http://www.informatik.uni-freiburg.de/~ciegler/BX/	書籍コミュニティサイトBookCrossing
http://isl.ifit.uni-klu.ac.at/	ハマキ販売サイトCuban cigars
http://kdd.ics.uci.edu/databases/msweb/msweb.html	マイクロソフト社のWeb アクセス (MSWeb)
http://ita.ee.lbl.gov/	Internet Traffic Archive : 公開Web ログのアーカイブ

の多様性の評価する [Fleder 07] も、アイテム集合全体を評価する点で興味深い。

図2の3段階の実行過程の中で、最初のデータ入力段階では、利用者の要求をうまく獲得することが重要だろう。まず、好きかどうかだけではなく、複数の評価項目について質問することで、どういう点で良かったかを知る方法がある。例えば、映画について、全体評価のほか、脚本や配役などの評価も利用する [Adomavicius 07] や、好みに加えて知っているかどうかもある [清水 07] などの研究がある。暗黙的な獲得でも、閲覧、サンプル視聴、購入の行動を区別する [Cho 07] などの研究もある。効果的な評価項目について検討する余地は広い。次に、14.1節のような、対話的に利用者の要求を探るアイデアも興味深いだろう。過去のセッションをも含めた長期的な嗜好パターンと、現在のセッションでの行動だけにに基づく短期的な嗜好パターンの両方を考慮する [Rafter 05] は発展の余地があるだろう。推薦直前の行動に応じて、推薦のパターンを変えるといった研究はほとんどない。[Smyth 03] では、現在の推薦リストの中で最適なアイテムを選択させるフィードバックを利用している。この研究では、推薦の方向性が正しいかどうかを探るだけの「探査アイテム」をリストに混ぜている。この探査アイテムを、要求の別の側面を探るようなものにとすると、いろいろな応用ができるだろう。

次に嗜好の予測段階について述べる。上記の複数の評価項目を利用する予測について [Adomavicius 05] の最後で論じている。入力段階で探った利用者の要求に合わせて重視する評価項目を変えるのはおもしろいだろう。現在の予測アルゴリズムは予測精度について最適化されているが、ほかの規準も同時に考慮するのも興味深いだろう。例えば、予測誤差を一定以下に保った状態で、推薦されるアイテムの分布の Gini 係数やエントロピーを最大化するといった定式化などがあるだろう。9.3節では、予測評価値の期待値だけが主に利用されている。だが、評価値が5になる確率が、ほかの評価値になる確率と比べて突出して高い場合と、ほかよりわずかに上回るだけの場合とでは、利用者が推薦から受ける印象は変わるだろう。また、現在は推薦するアイテムを個々に判断しているが、推薦リスト全体で最適化することを今後は重視していくべきだろう [McNee 06a]。推薦を受けるコンテキストを考慮するのも重要だろう。そうしたコンテキストの一つにグループに対する推薦がある [O'Connor 01, 山根 06]。全利用者に対して平均的に良い推薦や、誰にもあまり嫌われないような推薦など、いろいろな選択肢が考えられる。

最後の予測の提示段階では、推薦がより信用されるための説明付けが必要だろう。こうした研究は [Herlocker 00] にいくつも提案されているが、効果的な説明手法はわずかに二つだけだったと報告している。簡潔に推薦理由を示すのは困難な課題で、研究が待たれる。特に、

[Cooke 02] にもあるように、推薦リストに含まれるアイテムの構成は、利用者に与える印象に影響する。単に予測精度の高い順にアイテムを選択して推薦リストをつくるのではなく、推薦リスト全体の効果について調査・考察すべきだろう。

16.2 推薦システムの運用

推薦システムのアルゴリズムには、当初から効率性が求められてきた。CPU のマルチコア化に伴い並列化による大規模化 [Das 07] の需要は高まるだろう。また、機械学習の大規模化で注目されるオンラインストリームアルゴリズム [Lee 01, Nakamura 98, 徳山 07] はより積極的に推薦システムに導入されるべきだろう。また、アイテムや利用者の入換わりへの迅速な対処も必要だが、そうした研究はまだ不十分である。アイテムや利用者の追加に伴う逐次更新 [Weimer 08, 吉井 07] や、逆に利用者やアイテムの削除に対応できる逐次更新の研究も必要だろう。

推薦システムの導入を容易にする技術も必要である。協調フィルタリングでは、嗜好データの収集が導入への障害となる。[Melamed 07] のポイント制のような巧妙な動機づけが、データ収集には必要だろう。[高間 07, 吉高 07] のような新たな入力デバイスの利用も興味深い。一方の内容ベースフィルタリングでは、アイテム特徴のデータベースの構築・維持が問題である。アイテムが、文書の場合は情報検索の技術である TF-IDF、音楽の場合は音響信号が利用されている。しかし、これ以外ではアイテム特徴を自動抽出する試みは推薦システムではあまり見かけない。例えば、家具などでは大きさは重要だが、電子商取引サイトでは大きさによる指定での検索はあまり見かけない。カタログ、仕様書、Web 文書などから、固有表現技術を用いてこうした特徴を抽出し、利用する試みも必要だろう。これを行うためには、意味解釈が必要となるので、オントロジーなどの基盤整備も必要だろう。

その他、推薦システムの影響の拡大に伴いサクラ攻撃への対策 [Mobasher 07] はより重要になるだろう。現在は、異常値検出の技術が主に用いられるが、時間的な攻撃パターンを利用する [Zhang 06a] のように、サクラ攻撃特有の性質を活用した対策が待たれる。推薦をする側ではなく、利用する側の技術もおもしろいだろう。例えば、複数の推薦システムから推薦されるアイテムを比べて、販売側が自分の都合に合わせた、いわば「押し売り」のような推薦をしているかどうかを検出したりできないだろうか？ 推薦システムの構築・維持には、コスト・人的資源の制限から小規模サイトでは困難が伴う。複数のサイトが共同運用できる枠組み [神島 07b] も必要だろう。

以上、3回にわたって、推薦システムの設計指針についてまとめ、各種アルゴリズムをその特徴とともに紹介

した。本稿が、推薦システムの研究・開発に役立てば幸いである。

謝 辞

廣瀬勝一先生、山口高平先生、佐藤 健先生、岩田具治様、麻生英樹様、藤井 敦先生、村上知子様には、本稿に関する貴重なコメントをいただいた。J. Riedl 先生、J. Herlocker 先生には論文の詳細について教えていただいた。アマゾンジャパン様、アップルジャパン様、GroupLens プロジェクト様には WWW のスクリーンショットなどの掲載を許可いただいた。以上の方々に感謝する。

◇ 参 考 文 献 ◇

- [Adomavicius 05] Adomavicius, G. and Tuzhilin, A.: Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions, *IEEE Trans. on Knowledge and Data Engineering*, Vol. 17, No. 6, pp. 734-749 (2005)
- [Adomavicius07] Adomavicius, G. and Kwon, Y.: New recommendation techniques for multicriteria rating systems, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 48-55 (2007)
- [Agrawal 00] Agrawal, R. and Srikant, R.: Privacy-preserving data mining, *Proc. ACM SIGMOD Int'l Conf. on Management of Data*, pp. 439-450 (2000)
- [Agresti 03] Agresti, A., 渡邊裕之 ほか訳: カテゴリカルデータ解析入門, サイエンス社 (2003)
- [Ali 04] Ali, K. and van Stam, W.: TiVo: Making show recommendations using a distributed collaborative filtering Architecture, *Proc. 10th Int'l Conf. on Knowledge Discovery and Data Mining*, pp. 394-401 (2004)
- [麻生 03] 麻生英樹, 津田宏治, 村田 昇: パターン認識と学習の統計学. 新しい概念と手法, 統計科学のフロンティア, 第6巻, 岩波書店 (2003)
- [麻生 06] 麻生英樹, 小野智弘, 本村陽一, 黒川茂莉, 櫻井彰人: 協調フィルタリングと属性ベースフィルタリングの統合について, 信学技報, NC 2006.54 (2006)
- [Balabanović 97] Balabanović, M. and Shoham, Y.: Fab: Content-based, collaborative recommendation, *Commun. ACM*, Vol. 40, No. 3, pp. 66-72 (1997)
- [Basilico 04] Basilico, J. and Hofmann, T.: Unifying collaborative and content-based filtering, *Proc. 21st Int'l Conf. on Machine Learning*, pp. 65-72 (2004)
- [Basu 01] Basu, C., Hirsh, H., Cohen, W. W. and Nevill-Manning, C.: Technical paper recommendation: A study in combining multiple information sources, *J. Artificial Intelligence Research*, Vol. 14, pp. 231-252 (2001)
- [Basu 04] Basu, S., Bilenko, M. and Mooney, R. J.: A probabilistic framework for semi-supervised clustering, *Proc. 10th Int'l Conf. on Knowledge Discovery and Data Mining*, pp. 59-68 (2004)
- [Ben Schafer 01] Ben Schafer, J., Konstan, J. A. and Riedl, J.: E-commerce recommendation applications, *Data Mining and Knowledge Discovery*, Vol. 5, pp. 115-153 (2001)
- [Bergemann 06] Bergemann, D. and Ozmen, D.: Optimal pricing with recommender system, *ACM Conf. on Electronic Commerce*, pp. 43-51 (2006)
- [Bishop 06] Bishop, C. M.: *Pattern Recognition and Machine Learning*, Springer (2006)
- [Bishop 08] Bishop, C. M., 元田 浩ほか訳: パターン認識と機械学習上下, ベイズ理論による統計の予測, シュプリンガー・ジャパン (2007, 2008)
- [Boutillier 03] Boutillier, C., Zemel, R. S. and Marlin, B.: Active collaborative filtering, *Uncertainty in Artificial Intelligence*, Vol. 19, pp. 98-106 (2003)
- [Breese 98] Breese, J. S., Heckerman, D. and Kadie, C.: Empirical analysis of predictive algorithms for collaborative filtering, *Uncertainty in Artificial Intelligence*, Vol. 14, pp. 43-52 (1998)
- [Burke 02] Burke, R.: Hybrid recommender systems: Survey and experiments, *User-Modeling and User-Adapted Interactions*, Vol. 12, No. 4, pp. 331-370 (2002)
- [Burke 05] Burke, R., Mobasher, B., Bhaumik, R. and Williams, C.: Segment-based injection attacks against collaborative filtering recommender systems, *Proc. 5th IEEE Int'l Conf. on Data Mining*, pp. 577-580 (2005)
- [Burke 06] Burke, R., Mobasher, B., Williams, C. and Bhaumik, R.: Classification features for attack detection in collaborative recommender systems, *Proc. 12th Int'l Conf. on Knowledge Discovery and Data Mining*, pp. 542-547 (2006)
- [Canny 02a] Canny, J.: Collaborative filtering with privacy, *Proc. 2002 IEEE Symp. on Security and Privacy*, pp. 45-57 (2002)
- [Canny 02b] Canny, J.: Collaborative filtering with privacy via factor analysis, *Proc. 25th Annual ACM SIGIR Conf. on Research and Development in Information Retrieval*, pp. 238-245 (2002)
- [Cho 07] Cho, J., Kwon, K. and Park, Y.: Collaborative filtering using dual information sources, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 30-38 (2007)
- [Claypool 99] Claypool, M., Gokhale, A., Miranda, T., Murnikov, P., Netes, D. and Sartin, M.: Combining content-based and collaborative filters in an online newspaper, *ACM SIGIR Workshop on Recommender Systems: Algorithms and Evaluation* (1999)
- [Clifton] Clifton, C.: <http://www.cs.purdue.edu/homes/clifton/>
- [Clifton 02] Clifton, C., Kantarcioglu, M., Vaidya, J., Lin, X. and Zhu, M. Y.: Tools for privacy preserving distributed data mining, *SIGKDD Explorations*, Vol. 4, No. 2, pp. 28-34 (2002)
- [Condliff 99] Condliff, M. K., Lambda, D. M., Lewis, D. D. and Posse, C.: Bayesian mixed-effects models for recommender systems, *ACM SIGIR Workshop on Recommender Systems: Algorithms and Evaluation* (1999)
- [Cooke 02] Cooke, A. D. J., Sujan, H., Sujan, M. and Weitz, B. A.: Marketing the unfamiliar: the role of context and item-specific information in electronic agent recommendations, *J. Marketing Research*, Vol. 39, No. 4, pp. 488-497 (2002)
- [Cosley 03] Cosley, D., Lam, S. K., Albert, I., Konstan, J. A. and Riedl, J.: Is seeing believing? How recommender interfaces affect users' opinions, *Proc. SIGCHI Conf. on Human Factors in Computing Systems*, pp. 585-592 (2003)
- [Crammer02] Crammer, K. and Singer, Y.: Pranking with ranking, *Advances in Neural Information Processing Systems*, Vol. 13, pp. 641-647 (2002)
- [Das 07] Das, A., Datar, M., Garg, A. and Rajaram, S.: Google news personalization: Scalable online collaborative filtering, *Proc. 16th Int'l Conf. on World Wide Web*, pp. 271-280 (2007)
- [de Borda 95] de Borda, J.-C.: On elections by ballot (1784), McLean, I. and Urken, A. B., eds., *Classics of Social Choice*, chapter 5, pp. 81-89, The University of Michigan Press (1995)
- [Dwork 01] Dwork, C., Kumar, R., Naor, M. and Sivakumar, D.: Rank aggregation methods for the web, *Proc. 10th Int'l Conf. on World Wide Web*, pp. 613-622 (2001)
- [Felfernig 07] Felfernig, A., Friedrich, G. and Schmidt-Thieme, L.: Guest editors' introduction: Recommender systems, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 18-21 (2007)
- [Fleder 07] Fleder, D. and Hosanagar, K.: Recommender systems and their impact on sales diversity, *ACM Conference on Electronic Commerce*, pp. 192-199 (2007)
- [Frankowski 06] Frankowski, D., Cosley, D., Sen, S., Terveen, L. and Riedl, J.: You are what you say: Privacy risks of public Mentions, *Proc. 29th Annual ACM SIGIR Conf. on Research and Development in Information Retrieval*, pp. 565-572 (2006)
- [Good 99] Good, N., Ben Schafer, J., Konstan, J. A., Borchers, A., Sarwar, B., Herlocker, J. and Riedl, J.: Combining collaborative filtering with personal agents for better recommendations,

- Proc. 16th National Conf. on Artificial Intelligence*, pp. 439-446 (1999)
- [Herlocker 00] Herlocker, J. L., Konstan, J. A. and Riedl, J.: Explaining collaborative filtering recommendations, *Proc. Conf. on Computer Supported Cooperative Work*, pp. 241-250 (2000)
- [Herlocker 04] Herlocker, J. L., Konstan, J. A., Terveen, L. G. and Riedl, J. T.: Evaluating collaborative filtering recommender systems, *ACM Trans. on Information Systems*, Vol. 22, No. 1, pp. 5-53 (2004)
- [土方 04] 土方嘉徳: 情報推薦・情報フィルタリングのためのユーザプロファイリング技術, 人工知能学会誌, Vol. 19, No. 3, pp. 365-372 (2004)
- [土方 07a] 土方嘉徳ほか: 特集『利用者の好みをとらえ活かす一嗜好抽出技術の最前線』, 情報処理, Vol. 48, No. 9, pp. 955-1007 (2007)
- [土方 07b] 土方嘉徳: 嗜好抽出と情報推薦技術, 情報処理, Vol. 48, No. 9, pp. 957-965 (2007)
- [市川 07] 市川祐介: 協調フィルタリングを用いたレコメンドサービスの導入事例と課題, 情報処理, Vol. 48, No. 9, pp. 972-978 (2007)
- [IMDB] IMDB: <http://imdb.com/>: [The Internet Movie Database]
- [亀井 04] 亀井剛次, 船越 要, 赤埴淳一, 佐藤哲司: 個人の推薦に基づく個人間情報共有モデル, 人工知能学会論文誌, Vol. 19, No. 5, pp. 540-547 (2004)
- [神嶋 06] 神嶋敏弘: 推薦システム. 情報過多時代をのりきる, 情報の科学と技術, Vol. 56, No. 10, pp. 452-457 (2006)
- [神嶋 07a] 神嶋敏弘: 協調フィルタリングの課題: プライバシー, サクラ攻撃, 評価値のゆらぎ, 情報処理, Vol. 48, No. 9, pp. 966-971 (2007)
- [神嶋 07b] 神嶋敏弘, 赤穂昭太郎: 参加システムの嗜好パターンが異なる場合の集団協調フィルタリング, 人工知能学会研究会資料, SIG-FPAI-A702-03 (2007)
- [Kautz 97] Kautz, H., Selman, B. and Shah, M.: Combining social networks and collaborative filtering, *Commun. ACM*, Vol. 40, No. 3, pp. 63-65 (1997)
- [川前 07] 川前徳章, 高橋克巳, 山田武士: ユーザの興味とオブジェクトのトピックに着目した情報検索モデル, 信学論 (D), Vol. J90-D, No. 10, pp. 2746-2754 (2007)
- [川瀬 06] 川瀬直人, 大田原章雄, 木下和彦, 野本東, 高島有次: 特集『情報のフィルタリング』, 情報の科学と技術, Vol. 56, No. 10, pp. 445-481 (2006)
- [Kohrs 01] Kohrs, A. and Merialdo, B.: Improving collaborative filtering for new-users by smart object selection, *Proc. Int'l Conf. on Media Features* (2001)
- [Konstan 04] Konstan, J. A.: Introduction to recommender systems: Algorithms and evaluation, *ACM Trans. on Information Systems*, Vol. 22, No. 1, pp. 1-4 (2004)
- [Lam 04] Lam, S. T. K. and Riedl, J.: Shilling recommender systems for fun and profit, *Proc. 13th Int'l Conf. on World Wide Web*, pp. 393-402 (2004)
- [Lawrence 99] Lawrence, S., Lee Giles, C., and Bollacker, K.: Digital libraries and autonomous citation indexing, *IEEE Computer*, Vol. 32, No. 6, pp. 67-71 (1999)
- [Lawrence 01] Lawrence, R. D., Almasi, G. S., Kotlyar, V., Viveros, M. S. and Duri, S. S.: Personalization of supermarket product recommendations, *Data Mining and Knowledge Discovery*, pp. 11-32 (2001)
- [Lee 01] Lee, W. S.: Collaborative learning for recommender systems, *Proc. 18th Int'l Conf. on Machine Learning*, pp. 314-321 (2001)
- [Lindell 00] Lindell, Y. and Pinkas, B.: Privacy preserving data mining, in advances in cryptology, *CRYPTO2000*, LNCS 1880, pp. 36-54 (2000)
- [Linden 03] Linden, G., Smith, B. and York, J.: Amazon.com recommendations: Item-to-item collaborative filtering, *IEEE Internet Computing*, Vol. 7, No.1 (2003)
- [McNee 06a] McNee, S. M., Riedl, J. and Konstan, J. A.: Accurate is not always good: how accuracymetrics have hurt recommender systems, *Proc. SIGCHI Conf. on Human Factors in Computing Systems*, pp. 1097-1101 (2006)
- [McNee 06b] McNee, S. M., Riedl, J. and Konstan, J. A.: Making recommendations better: An analytic model for human-recommender interaction, *Proc. SIGCHI Conf. on Human Factors in Computing Systems*, pp. 1103-1108 (2006)
- [McSherry 05] McSherry, D.: Explanation in Recommender Systems, *Artificial Intelligence Review*, Vol. 24, pp. 179-197 (2005)
- [Melamed 07] Melamed, D., Shapira, B. and Elovici, Y.: MarCol: A market-based recommender system, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 74-78 (2007)
- [Mobasher 07] Mobasher, B., Burke, R., Bhaumik, R. and Sandvig, J. J.: Attacks and remedies in collaborative recommendation, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 56-63 (2007)
- [Mooney99] Mooney, R. J. and Roy, L.: Content-based book recommending using learning for text categorization, *ACM SIGIR Workshop on Recommender Systems: Algorithms and Evaluation* (1999)
- [元田 06] 元田 浩, 津本周作, 山口高平, 沼尾正行: データマイニングの基礎, オーム社 (2006)
- [MovieLens] MovieLens: <http://movielens.org/>
- [村上 05] 村上知子, 吉岡信和, 折原良平, 古川康一: CAM 法を用いた個人嗜好モデルに基づく商品推薦システム, 人工知能学会論文誌, Vol. 20, No. 5, pp. 346-355 (2005)
- [村上 07] 村上知子, 森紘一郎, 折原良平: 推薦結果の意外性を評価する指標の提案, 人工知能学会全国大会 (第 21 回) 論文集, 2C5-2 (2007)
- [中島 99] 中島義明ほか 編: 心理学辞典, 有斐閣 (1999)
- [Nakamura 98] Nakamura, A. and Abe, N.: Collaborative filtering using weighted majority prediction algorithms, *Proc. 15th Int'l Conf. on Machine Learning*, pp. 395-403 (1998)
- [沼尾 06] 沼尾雅之: プライバシーと AI, 人工知能学会誌, Vol. 21, No. 5, pp. 593-601 (2006)
- [O'Connor 01] O'Connor, M., Cosley, D., Konstan, J. A. and Riedl, J.: PolyLens: A recommender system for groups of users, *Proc. 7th European Conf. on Computer-Supported Cooperative Work*, pp. 199-218 (2001)
- [O'Donovan 05] O'Donovan, J. and Smyth, B.: Trust in recommender systems, *Int'l Conf. on Intelligent User Interfaces*, pp. 167-174 (2005)
- [O'Mahony 04] O'Mahony, M., Hurley, N., Kushmerick, N. and Silvestre, G.: Collaborative recommendation: A robustness analysis, *ACM Trans. on Internet Technology*, Vol. 4, No. 4, pp. 344-377 (2004)
- [Ono 05] Ono, C., Motomura, Y. and Asoh, H.: A study of probabilistic models for integrating collaborative and content-based recommendation, *Working Note of IJCAI-05: Multidisciplinary Workshop on Advances in Preference Handling* (2005)
- [小野 06] 小野智弘, 黒川茂莉, 本村陽一, 麻生英樹: 携帯電話ユーザのための映画嗜好モデル構築と映画推薦システム, 人工知能学会研究会資料, SIG-FPAI-A602-07 (2006)
- [小野 07] 小野智弘, 本村陽一, 麻生英樹: 携帯電話によるレコメンデーションシステム的一般ユーザによる評価実験, 人工知能学会全国大会 (第 21 回) 論文集, 2C5-1 (2007)
- [Pazzani 99] Pazzani, M. J.: A framework for collaborative, content-based and demographic filtering, *Artificial Intelligence Review*, Vol. 13, pp. 393-408 (1999)
- [Polat03] Polat, H. and Du, W.: Privacy-preserving collaborative filtering using randomized perturbation techniques, *Proc. 3rd IEEE Int'l Conf. on Data Mining*, pp. 625-628 (2003)
- [Popescul 01] Popescul, A., Ungar, L. H., Pennock, D. M. and Lawrence, S.: Probabilistic models for unified collaborative and content-based recommendation in sparse-data environments, *Uncertainty in Artificial Intelligence*, Vol. 17, pp. 437-444 (2001)
- [Rafter 05] Rafter, R. and Smyth, B.: Conversational collaborative recommendation - An experimental analysis, *Artificial Intelligence Review*, Vol. 24, pp. 301-318 (2005)
- [Resnick 97] Resnick, P. and Varian, H. R.: Recommender systems, *Commun. ACM*, Vol. 40, No. 3, pp. 56-58 (1997)
- [Ricci 07] Ricci, F. and Nguyen, Q. N.: Acquiring and revising

- preferences in a critique-based mobile recommender system, *IEEE Intelligent Systems*, Vol. 22, No. 3, pp. 22-29 (2007)
- [Rubens 07] Rubens, N. and Sugiyama, M.: Influence-based active learning for collaborative filtering, 人工知能学会研究会資料, SIG.FPAI-A702-01 (2007)
- [Senecal 04] Senecal, S. and Nantel, J.: The influence of online product recommendation on consumers' online choices, *J. Retailing*, Vol. 80, pp. 159-169 (2004)
- [清水 07] 清水拓也, 土方嘉徳, 西田正吾: 発見性を考慮した協調フィルタリングアルゴリズムにおける評価実験, 信学技報, WI2-2007-50 (2007)
- [新保 06] 新保史生: フィルタリングと法, 情報の科学と技術, Vol. 56, No. 10, pp. 475-481 (2006)
- [Sinha02] Sinha, R. and Swearingen, K.: The role of transparency in recommender systems, *Proc. SIGCHI Conf. on Human Factors in Computing Systems*, pp. 830-831 (2002)
- [Smyth 03] Smyth, B. and McGinty, L.: The power of suggestion, *Proc. 18th Int'l Conf. on Artificial Intelligence*, pp. 127-132 (2003)
- [Smyth 04] Smyth, B., McGinty, L., Reilly, J. and McCarthy, K.: Compound critiques for conversational recommender systems, *Proc. IEEE/WIC/ACM Int'l Conf. on Web Intelligence*, pp. 145-151 (2004)
- [Swearingen 01] Swearingen, K. and Sinha, R.: Beyond algorithms: An HCI perspective on recommender systems, *ACM SIGIR Workshop on Recommender Systems* (2001)
- [Sweeney 00] Sweeney, L.: Uniqueness of simple demographics in the U.S. Population, in LIDAP-WP4 (2000), <http://privacy.cs.cmu.edu/dataprivacy/papers/LIDAP-WP4abstract.html>
- [高間 07] 高間康史, 難波広樹, 岩瀬徳宏, 服部俊一, 武藤優樹, 庄司俊寛: テレビ視聴時の情報推薦に基づくヒューマン・ロボットコミュニケーション, 人工知能学会全国大会(第21回)論文集, 2D5-5 (2007)
- [Thompson 04] Thompson, C. A., Göker, M. H. and Langley, P.: A personalized system for conversational recommendation, *J. Artificial Intelligence Research*, Vol. 21, pp. 393-428 (2004)
- [徳永 99] 徳永健伸: 情報検索と言語処理, 言語と計算シリーズ, 第5巻, 東京大学出版会 (1999)
- [徳山 07] 徳山 豪: オンラインアルゴリズムとストリームアルゴリズム, アルゴリズム・サイエンス, 第5巻, 共立出版 (2007)
- [Vaidya 05] Vaidya, J., Clifton, C. and Zhu, M.: *Privacy Preserving Data Mining*, *Advances in Information Security*, Springer-Verlag (2005)
- [渡辺 05] 渡辺澄夫, 萩原克幸, 赤穂昭太郎, 本村陽一, 福水健次, 岡田真人, 青柳美輝: 学習システムの理論と実現, 森北出版 (2005)
- [Weimer 08] Weimer, M., Karatzoglou, A., Le, Q. and Smola, A.: COFI RANK, Maximum margin matrix factorization for collaborative ranking, *Advances in Neural Information Processing Systems*, Vol. 20 (2008)
- [山根 06] 山根康男, 官上大輔, 河合由起子, 津田 宏, 田中克己: グループ適応型システムのための満足度を考慮した推薦方式の提案, 第17回データ工学ワークショップ(DEWS2005), 1A-i7 (2006)
- [吉井 06] 吉井和佳, 後藤真孝, 駒谷和範, 尾形哲也, 奥乃博: ユーザの評価と音響的特徴との確率的統合に基づくハイブリッド型楽曲推薦システム, 情処学研報, 2006-MUS-66 (2006)
- [吉井 07] 吉井和佳, 後藤真孝, 駒谷和範, 尾形哲也, 奥乃博: 楽曲推薦システムの効率性とスケーラビリティの改善のための確率的推薦モデルのインクリメンタル学習法, 情処学研報, 2007-MUS-71 (2007)
- [吉高 07] 吉高淳夫, 脇山孝貴, 平嶋 宗: 絵画を例とした鑑賞活動の共有に基づく情報推薦, 人工知能学会全国大会(第21回)論文集, 2B4-8 (2007)
- [Yu 03] Yu, K., Schwaighofer, A., Tresp, V., Ma, W.-Y. and Zhang, H.-J.: Collaborative ensemble learning: Combining collaborative and content-based information filtering via hierarchical Bayes, *Uncertainty in Artificial Intelligence*, Vol. 19, pp. 616-623 (2003)
- [Zhang 06a] Zhang, S., Chakrabarti, A., Ford, J. and Makedon, F.: Attack detection in time series for recommender systems, *Proc. 12th Int'l Conf. on Knowledge Discovery and Data Mining*, pp. 809-814 (2006)
- [Zhang 06b] Zhang, S., Ouyang, Y., Ford, J. and Makedon, F.: Analysis of a low-dimensional linear model under recommendation attacks, *Proc. 29th Annual ACM SIGIR Conf. on Research and Development in Information Retrieval*, pp. 517-524 (2006)
- [Ziegler 05] Ziegler, C.-N., McNee, S. M., Konstan, J. A. and Lausen, G.: Improving recommendation lists through topic diversification, *Proc. 14th Int'l Conf. on World Wide Web*, pp. 22-32 (2005)

2008年1月17日 受理

著者紹介

神寫 敏弘(正会員)は, 前掲(Vol.23, No.1, p.103)参照.